

# Test et comparaison de modèles d'apprentissage continu

Yacine SAHNOUNE    Azouaou LOUAIFI    Abdelkarim BENCHEIKH

Février 2025

## Résumé

L'apprentissage continu constitue un défi majeur dans le domaine de l'intelligence artificielle. Les modèles doivent apprendre de nouvelles connaissances sans perdre celles précédemment acquises. Cette étude compare l'efficacité des architectures Perceptron Multicouche (MLP) et d'un modèle de réseau neuronal convolutif (CNN), qui est LeNet-5, combinées à différentes stratégies utilisées dans l'apprentissage continu. Nous avons testé ces approches sur deux jeux de données : MNIST et FashionMNIST, permettant ainsi d'analyser l'impact de la complexité des jeux de données sur les performances des modèles. À chaque expérience, on introduit deux classes aux modèles et on les évalue via des métriques telles que la précision globale, le taux d'oubli et l'utilisation des ressources computationnelles. Les résultats ont montré que la stratégie d'apprentissage continu impacte significativement les performances des modèles. Sur MNIST, la stratégie GEM a permis à MLP de maintenir des performances très proches de celles obtenues par LeNet-5. L'approche Experience Replay donne une précision globale élevée (90%) pour LeNet-5, contrairement à MLP qui enregistre des performances moins conséquentes (50%). Sur le jeu de données FashionMNIST, plus complexe, les deux modèles atteignent 80% de précision avec une approche GEM et 50% pour l'approche ER, avec un léger avantage pour LeNet-5 de 3%. Le modèle LeNet-5 enregistre de meilleurs résultats et ce, avec des coûts computationnels similaires à MLP et un nombre de paramètres inférieur. L'approche naïve donne des précisions faibles indépendamment du modèle utilisé.

**Mots-clés :** Apprentissage continu, réseaux de neurones, oubli catastrophique, CNN, MLP, GEM, Experience Replay

## 1 Introduction

L'apprentissage continu est une branche du machine learning qui repose sur l'idée qu'une machine peut apprendre du monde extérieur tout au long de son cycle de vie. Il permet de développer progressivement une base de connaissances sans nécessiter un réentraînement à chaque nouvelle donnée. En raison de sa nature incrémentale, il est souvent désigné sous les termes apprentissage incrémental ou apprentissage tout au long de la vie, comme le soulignent Wang et al. (1).

Cependant, il est confronté à plusieurs défis majeurs liés à l'intégration de nouvelles données sans perdre ses anciennes connaissances, phénomène appelé oubli catastrophique. Il est également fortement confronté au dilemme plasticité-stabilité, qui mesure l'équilibre entre la capacité d'un modèle à apprendre de nouvelles tâches (plasticité) et à conserver les acquis précédents (stabilité). Un excès de stabilité rigidifie le modèle, tandis qu'une trop grande plasticité entraîne un oubli des connaissances antérieures.

Un autre défi concerne la disponibilité des données, car l'apprentissage continu doit fonctionner dans un environnement où les données évoluent constamment, ces dernières sont parfois non annotées ou présentent des déséquilibres entre les classes.

Dans cette étude, nous effectuons une comparaison entre deux modèles d'architectures neuronales sur des jeux de données avec des stratégies d'apprentissage continu. Nous avons structuré notre étude en plusieurs parties : une première partie aborde l'état de l'art de l'apprentissage continu, décrivant les différents scénarios, approches, jeux de données et modèles utilisés dans l'apprentissage continu. Une deuxième partie présente la méthodologie expérimentale, incluant les jeux de données, les modèles et stratégies utilisés ainsi que les métriques d'évaluation. La troisième partie présente les résultats obtenus et compare les performances entre les modèles. La quatrième section contient les discussions autour des directions futures. Enfin, une dernière partie conclut en présentant une synthèse de l'étude réalisée.

## 2 État de l'art

### 2.1 Les différents scénarios de l'apprentissage continu

Au début, Delange et al. (2) soulignent que l'idée était de segmenter les données par tâches distinctes, que ce soit par tâche, domaine ou classe. Dans l'apprentissage incrémental par tâche (ou Task Incremental Learning Task-IL), le modèle est entraîné séquentiellement à la réalisation de tâches distinctes, avec pour objectif de maîtriser les nouvelles tâches tout en conservant les performances sur les tâches précédentes. Dans l'apprentissage incrémental par domaine (ou Domain Incremental Learning Domain-IL), le modèle apprend à réaliser la même tâche mais dans différents domaines ou conditions qui arrivent séquentiellement, tout en maintenant les mêmes performances sur les domaines précédents. L'apprentissage incrémental par classe (Class Incremental Learning ou Class-IL) est le troisième scénario majeur en apprentissage continu. Le modèle vise à apprendre continuellement de nouvelles classes tout en maintenant la capacité de reconnaître les classes précédemment apprises.

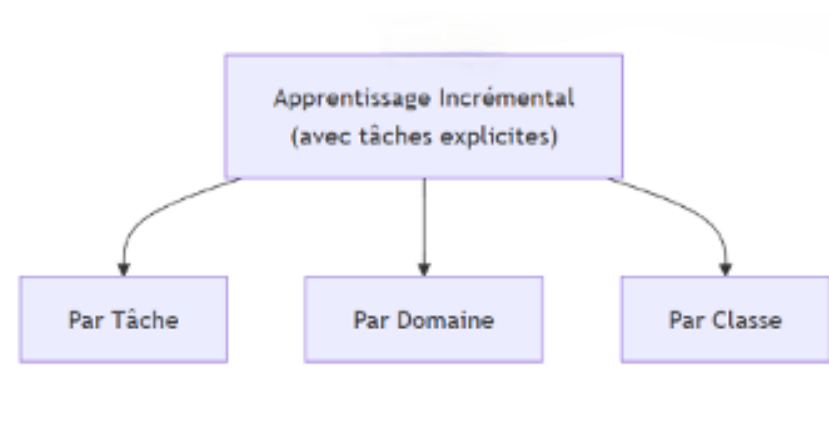


FIGURE 1 – Les différents scénarios de l'apprentissage continu

### 2.2 Les approches de l'apprentissage continu

Les méthodes d'apprentissage continu se déclinent en trois grandes catégories selon leur principe fondamental d'après Delange et al. (2). D'une part, les approches basées sur le replay réutilisent ou génèrent des données provenant des tâches antérieures afin de maintenir les connaissances acquises. On peut citer iCaRL (3), ER (6) ou encore GEM (5). D'autre part, les

approches de régularisation ajoutent des termes de pénalisation qui limitent la modification excessive des paramètres pour protéger l'information déjà apprise. EWC (4) et SI (7) en sont des exemples notables. Enfin, les méthodes d'isolation des paramètres allouent des sous-ensembles spécifiques de paramètres à chaque tâche afin de réduire les interférences, comme illustré par PackNet (8).

## 2.3 Modèles en Apprentissage Continu

### 2.3.1 Perceptrons Multicouches (MLP)

Le MLP (Multi-Layer Perceptron) est l'une des architectures de base en deep learning. Il est constitué de couches entièrement connectées où chaque neurone d'une couche est relié à tous ceux de la couche suivante. Grâce à des fonctions d'activation non linéaires comme ReLU, Sigmoid ou Tanh, il peut apprendre des relations complexes entre les entrées et les sorties. Historiquement, les MLP ont marqué le début de l'étude des réseaux de neurones, selon l'étude de Bishop (9). Cependant, même s'ils fonctionnent bien sur des données simples ou tabulaires, ils ne sont pas adaptés au traitement d'images, car ils ne capturent pas la structure locale et hiérarchique des informations visuelles.

### 2.3.2 Convolutional Neural Networks (CNN)

Selon Parisi et al. (10), les CNN (Convolutional Neural Networks) sont une architecture de réseaux neuronaux spécifiquement élaborée pour le traitement d'images, exploitant leur structure spatiale. À l'inverse des MLP qui établissent une connexion dense entre chaque neurone, les CNN font appel à des couches de convolution pour déceler automatiquement des caractéristiques locales comme les contours, les textures et les formes. Ces opérations sont suivies par des processus de pooling qui diminuent la dimensionnalité tout en préservant l'information cruciale. Cette méthode hiérarchique facilite la modélisation de la complexité visuelle. Cette architecture est la base de plusieurs modèles emblématiques : LeNet-5 (11), considéré comme l'un des premiers réseaux de neurones convolutifs, a pavé la voie en matière de reconnaissance de chiffres manuscrits. D'autre part, VGG (15) se particularise par son approche consistant à superposer des convolutions plus petites afin d'en tirer des représentations de plus en plus abstraites. ResNet (14) innove.

## 2.4 Jeux de données de référence : benchmarks

MNIST a été introduit par LeCun et al. (11) en 1998. Depuis ce jour, il est utilisé comme benchmark dans le domaine du Machine Learning et contient 70 000 images, dont 60 000 pour l'entraînement et 10 000 pour le test. Chaque image est représentée en  $28 \times 28$  pixels et contient un chiffre recueilli à partir des écritures de lycéens et d'employés de bureau différents.

CIFAR-10 (Canadian Institute For Advanced Research) a été développé par l'équipe de chercheurs de l'institut de CIFAR (12). Il se compose de 60 000 images réparties en 10 classes, chaque classe contenant 6 000 images, réparties en 5 000 pour l'entraînement et 1 000 pour le test. Une image est coloriée et mesure  $32 \times 32$  pixels. Les 10 classes représentent des avions, des voitures, des oiseaux, des chats, des cerfs, des chiens, des grenouilles, des chevaux, des bateaux et des camions.

ImageNet a été créé par Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li et Li Fei-Fei en 2009 (13). Depuis, il est largement utilisé comme benchmark dans le domaine du Deep Learning et de la vision par ordinateur, et contient environ 14 millions d'images annotées, réparties en plus de 20 000 catégories d'objets. Chaque image est associée à une ou plusieurs

étiquettes basées sur la hiérarchie de WordNet et ImageNet a joué un rôle clé dans les avancées des architectures de réseaux neuronaux.

## 3 Méthodologie

### 3.1 Bibliothèque

Dans notre étude, pour l’implémentation de notre comparaison, nous avons utilisé la bibliothèque Avalanche (16), une bibliothèque pour l’apprentissage continu. Le modèle MLP, les jeux de données et les mesures de performances utilisées sont ceux fournis par la bibliothèque.

### 3.2 Jeux de données

Nous avons sélectionné deux jeux de données pour réaliser le test et la comparaison de deux modèles d’apprentissage continu sur une tâche de classification incrémentale. Le premier jeu de données est SplitMNIST, une variante du jeu de données originel MNIST, qui le divise en 5 expériences composées chacune de deux classes. Cette division permet une meilleure simulation du scénario d’arrivée séquentielle des classes au modèle. Le deuxième jeu de données utilisé est SplitFMNIST, représentant des articles vestimentaires. Ce dernier est semblable à MNIST dans sa structure, mais présente un niveau de complexité supérieur en raison des formes et textures plus complexes. MNIST est un jeu de données souvent utilisé dans la littérature scientifique et est vu comme une référence historique. Il nous permet de mesurer l’oubli sur des formes simples et la capacité basique d’apprentissage des modèles. FashionMNIST représente un niveau de difficulté supérieur en raison des formes plus complexes présentes dans le jeu de données par rapport à MNIST.

### 3.3 Modèles

Dans cette étude, nous comparons deux architectures neuronales pour évaluer leur comportement soumis à de l’apprentissage continu. La première est un réseau de neurones convolutifs (CNN) historiquement connu, LeNet-5 (11), qui a montré de bons résultats sur le jeu de données MNIST, et un perceptron multicouche (MLP). Le MLP est composé d’une couche d’entrée de 28x28 et de quatre couches cachées de 600 neurones, chacune utilisant une activation ReLU. Le modèle LeNet-5 est composé de deux couches convolutives, chacune appliquant des filtres et une activation Tanh. Les deux modèles sont configurés pour produire des sorties sur 10 classes correspondant aux dix classes de MNIST et FashionMNIST, et sont entraînés avec les mêmes hyperparamètres, qui sont détaillés dans le Tableau 1.

Paramètre	MLP	LeNet-5
Optimiseur	Adam	Adam
Taux d’apprentissage	0.001	0.001
Taille du batch	128	128
Nombre d’époques par expérience	10	10

TABLE 1 – Paramètres d’entraînement utilisés pour MLP et LeNet-5

### 3.4 Mesures d’évaluation

Les critères employés pour comparer les deux architectures sont la précision, l’oubli catastrophique et l’efficacité en termes de calcul. La précision est évaluée par expérience, où chaque

expérience comporte deux catégories. Nous avons également évalué la précision globale sur l'ensemble du jeu de données. La deuxième mesure, l'oubli catastrophique, évalue la perte d'information entre les expériences et sert à quantifier la diminution des performances par rapport aux mesures précédentes. La dernière mesure concerne l'efficacité computationnelle, durant laquelle nous avons mesuré l'utilisation de la RAM et du GPU.

### 3.5 Stratégies d'apprentissage continu

Pour faire face à l'oubli catastrophique, nous avons implémenté sur les architectures trois approches d'apprentissage continu : Une approche naïve (baseline) servant de référence de base. Deux approches replay-based, Experience Replay (ER) et Gradient Episodic Memory (GEM). L'approche naïve apprend séquentiellement chaque nouvelle expérience sur les données courantes et n'applique aucun mécanisme pour contrer l'oubli catastrophique. ER maintient un ensemble de 1 000 exemples des données précédentes dans un buffer, qui sont ensuite mélangées avec les données courantes durant l'entraînement. La stratégie GEM conserve 1 000 exemples représentatifs pour chaque expérience afin de s'assurer que la mise à jour des paramètres du modèle sur la tâche courante ne dégrade pas les performances sur les expériences précédentes. L'optimisation est faite avec Adaptive Moment Estimation (Adam), avec un taux d'apprentissage de 0.001, des mini-batches de taille 16 en entraînement et 128 en évaluation. La force de mémoire pour GEM est de 0.5.

## 4 Présentation des résultats

### 4.1 MNIST

Sur le jeu de données MNIST, nous avons obtenu des résultats significatifs entre les deux modèles (fig 2). Les résultats démontrent une supériorité du modèle LeNet-5 par rapport à MLP, indépendamment de la stratégie d'apprentissage continu adoptée. Sur la performance globale, les résultats obtenus sur LeNet-5 sont meilleurs, en particulier dans le cas de l'Experience Replay, où l'écart entre les deux modèles atteint presque 22%. Le modèle naïf CNN enregistre une précision globale de 20,49%, alors que le Naïve MLP réalise 10,28%. En termes de stabilité d'apprentissage, l'architecture CNN maintient des performances élevées et constantes à travers les différentes expériences, tandis que MLP est stable lorsque l'on adopte la stratégie GEM, mais présente une grande variabilité dans le cas ER. Les mesures d'oubli démontrent encore la supériorité du modèle LeNet-5, qui se distingue avec le taux d'oubli le plus faible. MLP avec ER est la combinaison qui souffre de l'oubli catastrophique le plus important, ce qui explique la faible précision obtenue en comparaison des autres combinaisons. Les mesures de consommation de ressources computationnelles sont similaires pour les deux modèles. Cette similarité dans l'utilisation des ressources de la part de LeNet-5, malgré des performances significativement meilleures, souligne l'efficacité de ce modèle. Ces résultats mettent en évidence la supériorité du modèle LeNet-5 pour l'apprentissage incrémental de classe sur le jeu de données MNIST.

Cette supériorité se manifeste par : une performance globale plus élevée, même quand aucune stratégie d'apprentissage continu n'est appliquée, une meilleure stabilité d'apprentissage, et une résistance accrue face à l'oubli catastrophique, tout en ayant le même coût computationnel que le modèle MLP.

### 4.2 FashionMNIST

Dans le cas d'un jeu de données plus complexe, les performances globales des modèles baissent même en adoptant la stratégie optimale (fig 3). On observe, dans le cadre de l'ap-




FIGURE 2 – Résultats sur le jeu de données MNIST

proche GEM que les deux modèles présentent des performances similaires (0.12% de différence contrairement à 3.3% pour le jeu de données précédent). En examinant l'évolution de la précision et l'oubli au cours des expériences les deux modèles conservent des trajectoires presque similaires. MLP affiche une légère supériorité dans les expériences 1 et 3, cependant LeNet-5 compense avec une meilleure performance dans les autres expériences. Dans le contexte de ER les différences entre les performances des deux modèles est plus prononcé, bien que toujours légères. CNN affiche une précision globale de 56,7% contre 53,3% pour MLP. Cette différence est reflétée dans la précision au cours des expériences, où CNN maintient un léger avantage tout en affichant un oubli par expérience inférieur. Dans l'approche Naïve, les deux architectures atteignent la même précision globale montrant aucune capacité des deux modèles à préserver les connaissances des expériences précédentes. Concernant l'utilisation des ressources, les deux modèles affichent la même consommation en termes de puissance computationnelle.

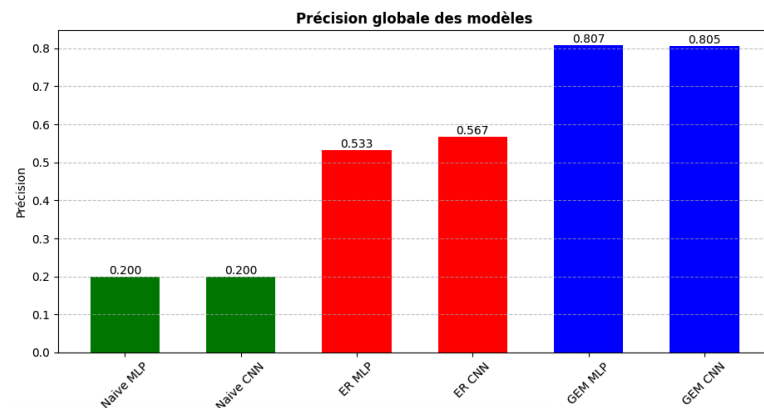


FIGURE 3 – Mesure de la précision globales par modèle et approche (FashionMNIST)






FIGURE 4 – Mesure de l'oubli et de la précision par expérience (FashionMNIST)

Sur les deux jeux de données on remarque que la stratégie s'avère être un facteur qui a son importance dans les performances des modèles. Dans l'approche naïve, les deux modèles montrent une incapacité totale à conserver les connaissances des expériences précédentes. ER apporte une amélioration significative pour les modèles et particulièrement pour LeNet-5 qui affiche une précision de 90% dans le jeu de données MNIST. La stratégie GEM semble celle qui offre la meilleure robustesse face à l'oubli catastrophique, où les deux modèles montrent d'excellents résultats sur MNIST (97% pour LeNet-5 et 94% pour MLP) et de bons résultats sur un jeu de données plus complexe comme FashionMNIST (environ 80% pour les deux modèles). Les résultats montrent donc un aspect particulièrement intéressant qui est l'interaction entre la stratégie et l'architecture. Avec GEM les différences de performances entre les deux modèles tendent à s'atténuer, suggérant qu'une bonne approche d'apprentissage continu peut permettre de compenser les limitations des architectures plus simples, comme c'est le cas pour MLP.

## 5 Directions futures

Dans cette étude nous avons utilisé des méthodes Replay Based comme mécanisme pour contrer l'oubli catastrophique de l'apprentissage incrémental de classe sur des modèles avec des architectures différentes. Des axes d'investigation ainsi que pistes prometteuses pour l'amélioration et l'extension de cette recherche peuvent être l'utilisation de méthodes d'approches différentes. Notre étude s'est basée sur des jeux de données relativement simple comme MNIST et FashionMNIST, qui sont des jeux de données en noir et blanc relativement simples, l'extension à des scénarios plus complexes avec des images couleurs et des formes plus complexes (jeu de données CIFAR ou CORe50 par exemple), ou même des scénarios d'apprentissage continu plus réalistes (flux de données non uniformes ou changements de distribution) permet de mieux cerner les limites des modèles et approches dans des conditions plus proches de la réalité.

## 6 Conclusion

Dans ce travail, nous avons étudié l'état de l'art de l'apprentissage continu, les différentes approches, méthodes, scénarios ainsi que les modèles les plus utilisés. Nous avons ensuite réalisé une étude comparative entre des architectures MLP et CNN dans un scénario d'apprentissage incrémental de classe, appliquée aux jeux de données MNIST et FashionMNIST. La comparaison a été effectuée sur deux stratégies d'apprentissage continu ainsi qu'une stratégie naïve utilisée comme référence. Nous avons ensuite fait une analyse des résultats obtenus qui a mis en évidence l'importance des méthodes d'apprentissage continu dans la préservation des connaissances et cela s'est illustré par la différence entre les résultats très faibles des approches naïves et ceux obtenus avec une stratégie pour contrer l'oubli catastrophique, et ce indépendamment du modèle utilisé. Nous avons aussi vu que le modèle LeNet-5 offre des résultats supérieurs à ceux de

MLP et ce, avec le même coût computationnel. L'étude a aussi permis de mieux comprendre l'importance d'une bonne combinaison modèle-stratégie notamment pour le modèle MLP qui, associé à la stratégie GEM, voit ses performances être plus proche de ceux du modèle LeNet-5.

Cette première expérience de recherche a été enrichissante et nous a permis d'acquérir des bases aussi bien dans la démarche scientifique, notamment dans l'interprétation des résultats parfois contre-intuitifs , que dans le vaste domaine qu'est l'apprentissage continu.



# Références

- [1] Wang, H., Liu, Y., & Chen, Z. (2023). *Lifelong Learning in Neural Networks : Tackling Catastrophic Forgetting and the Stability-Plasticity Dilemma*. IEEE Transactions on Neural Networks and Learning Systems, 34(2), 456–470.
- [2] Delange, M., Aljundi, R., Masana, M., Parisot, S., Jia, X., Leonardis, A., Slabaugh, G., & Tuytelaars, T. (2021). *A continual learning survey : Defying forgetting in classification tasks*. IEEE Transactions on Pattern Analysis and Machine Intelligence.
- [3] S.-A. Rebuffi, A. Kolesnikov, G. Sperl, and C. H. Lampert, *iCaRL : Incremental Classifier and Representation Learning*, in *CVPR*, 2017, pp. 2001–2010.
- [4] J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska *et al.*, *Overcoming catastrophic forgetting in neural networks*, PNAS, p. 201611835, 2017.
- [5] D. Lopez-Paz and M. Ranzato, *Gradient episodic memory for continual learning*, in *Advances in Neural Information Processing Systems*, 2017, pp. 6467–6476.
- [6] D. Rolnick, A. Ahuja, J. Schwarz, T. Lillicrap, and G. Wayne, *Experience replay for continual learning*, in *Advances in Neural Information Processing Systems*, 2019, pp. 350–360.
- [7] F. Zenke, B. Poole, and S. Ganguli, *Continual learning through synaptic intelligence*, in *ICML*. JMLR.org, 2017, pp. 3987–3995.
- [8] A. Mallya and S. Lazebnik, *PackNet : Adding multiple tasks to a single network by iterative pruning*, in *CVPR*, 2018, pp. 7765–7773.
- [9] Bishop, C. M. (1995). *Neural Networks for Pattern Recognition*. Oxford University Press.
- [10] Parisi, G. I., Kemker, R., Part, J. L., Kanan, C., & Wermter, S. (2019). *Continual lifelong learning with neural networks : A review*. Neural Networks, 113, 54–71.
- [11] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, *Gradient-Based Learning Applied to Document Recognition*, *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [12] A. Krizhevsky, *Learning Multiple Layers of Features from Tiny Images*, Technical Report, University of Toronto, 2009.
- [13] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, *ImageNet : A Large-Scale Hierarchical Image Database*, in *CVPR*, 2009, pp. 248–255.
- [14] Kim, J. Y., & Choi, D. W. (2021, May). *Split-and-bridge : Adaptable class incremental learning within a single neural network*. In *Proceedings of the AAAI Conference on Artificial Intelligence* (Vol. 35, No. 9, pp. 8137-8145).
- [15] Hung, C. Y., Tu, C. H., Wu, C. E., Chen, C. H., Chan, Y. M., & Chen, C. S. (2019). *Compacting, picking and growing for unforgetting continual learning*. in *Advances in neural information processing systems*, 32.
- [16] Carta, A., Pellegrini, L., Cossu, A., Hemati, H., & Lomonaco, V. (2023). *Avalanche : A pytorch library for deep continual learning*. in *Journal of Machine Learning Research*, 24(363), 1-6.

**Lien dépôt git contenant le code**

<https://forge.univ-lyon1.fr/p2414115/mif11>